

Nom du candidat : Nicodème

Prénoms : Corentin

N° Candidat : A BCPST - 38178

Noms des auteurs

Rigaud Hélène
Flandin Thomas
Nicodème Corentin

en cas de travail commun

Dominante BIOLOGIE

Dominante GÉOLOGIE

MIXTE

Surligner la dominante du TIPE

BANQUE AGRO-VETO - Session 2022

T.I.P.E.

Maximum 6 à 10 pages (illustrations comprises), 20 000 caractères maximum, Times New Roman 12 ou Arial 10, interligne simple espaces compris.

IMPORTANT : n'inscrire sur cette couverture aucune référence à l'établissement scolaire.

TITRE : INTELLIGENCE ARTIFICIELLE ET PREVENTION DE MALADIES THORACIQUES

RÉSUMÉ (en six lignes):

Notre étude porte sur la reconnaissance de clichés radiographiques grâce à une intelligence artificielle pour prévenir plus rapidement et efficacement les pathologies thoraciques au sein d'un système de santé toujours plus sollicité. Pour cela, nous avons trié à la main une banque de données en faisant appel à une radiologue, ce qui nous a permis d'entraîner un réseau neuronal artificiel capable de distinguer les maladies. Nous avons tiré d'une étude statistique et des résultats obtenus les potentielles améliorations de l'IA et les limites de notre démarche personnelle.

Nombre de caractères (espaces compris) : 19755

Le document, constitué uniquement de feuilles blanches A4, sera **simplement agrafé**, avec en couverture cette présentation.

Aucune couverture de couleur, cartonnée, rhodoïd ou autre.

Il ne sera surtout pas relié avec une spirale, ou une réglette.

Introduction

La médecine fait aujourd'hui de nombreux progrès grâce à l'utilisation de nouvelles technologies, notamment grâce à l'intelligence artificielle. La création d'une intelligence artificielle capable de trier des clichés radiographiques selon certaines maladies est d'actualité. Ce tri en fonction des maladies pourrait prévenir l'arrivée de ces pathologies plus rapidement et plus efficacement. Cette IA permettrait de faire une première sélection pour les radiologues. Les cas bénins et les personnes saines pourraient laisser la place aux patients urgents qui seraient pris en charge plus rapidement. Cela éviterait ainsi la surcharge des hôpitaux. Nous nous sommes donc demandés :

L'intelligence artificielle peut-elle prévenir l'aggravation des maladies thoraciques, à partir de simples clichés radiographiques ?

La création de notre propre logiciel nous a permis de mettre au point une intelligence artificielle de reconnaissance de clichés radiographiques, basée sur le réseau neuronal convolutif.

Sommaire

I – <u>La récupération des banques de données de radiographie</u>	1
A) Les difficultés pour obtenir une banque de données libre de droit	
B) L'exploitation de deux banques de données.....	2
C) Le choix de la banque et des maladies à étudier	
II – <u>Le tri des maladies à la main</u>	
A) Les techniques d'identification des maladies	
B) Etude statistique sur l'âge et le sexe	3
III – <u>La création de l'intelligence artificielle</u>	5
A) Fonctionnement du réseau neuronal convolutif.....	
B) Création du programme informatique	6
IV – <u>Résultats et interprétation</u>	7
A) Présentation des résultats fournis par l'IA	
B) Quelques erreurs de l'IA et les améliorations possibles	8
<u>Conclusion</u>	9
<u>Sitographie</u>	10
<u>Contact</u>	

I – La récupération des banques de données de radiographie

A) Les difficultés pour obtenir une banque de données libre de droit

Nous avons d'abord tenté de trouver une banque de données d'imagerie médicale française. Nous avons contacté des étudiants en médecine pour obtenir leur banque d'étude mais il est aujourd'hui interdit de divulguer ces sites car, depuis la loi d'août 2011^[1], anonymiser les images ne suffit pas, il faut aussi avoir l'accord écrit du patient pour pouvoir utiliser sa radiographie pour une étude scientifique. Or, pour bien entraîner une intelligence artificielle, il faut des banques de données très importantes. Nous nous sommes donc orientés vers les Instituts américains de la santé^[2], le pays n'étant pas soumis aux mêmes lois, qui propose publiquement ses ressources dans l'intérêt de l'apprentissage artificiel.

B) L'exploitation de deux banques de données



Figure 1 : Radiographie prise en réanimation

La banque américaine apporte environ 100000 images de 14 maladies différentes et une classe « no finding » (pathologies non identifiées), déjà triées par une IA. Mais ces données réunissent à la fois des images de bonne qualité et des images inexploitables, certaines provenant de personnes en réanimation, ce qui entraîne une superposition de la matière donc images blanches (*Figure 1*)^[3]. Il y a également des radiographies montrant plusieurs pathologies à la fois, trop difficiles à exploiter, certaines en masquant d'autres.

Nous avons trouvé une deuxième banque^[4], composée uniquement de pneumonies et de personnes saines. Les images sont de meilleure qualité mais comme nous voulions étudier plusieurs maladies, et que la qualité des deux banques est différente (sûrement dû à l'appareil de radiographie), nous avons choisi d'utiliser uniquement la première banque de données en triant nous-mêmes les images pour former notre propre base de travail.

C) Le choix de la banque et des maladies à étudier

Sur les conseils d'une radiologue, le docteur Céline Barcelo^[A] que nous avons rencontrée, nous avons choisi des maladies par catégorie en fonction de la densité de matière observée dans le poumon, c'est-à-dire le taux de blanc sur l'image. Nous avons donc privilégié une maladie particulière dans chacune de ces catégories :

- La masse pour le **champ pulmonaire hyperdense** pouvant traduire une infection ou un cancer.
- L'emphysème pour un **champ pulmonaire hypodense**.
- La cardiomégalie pour une **ombre cardiaque anormale**.
- La pneumonie faisant également partie de la catégorie de poumon hyperdense mais dont la densité du tissu est moins concentrée que celle de la masse.

Ce sont ces maladies qui ont été choisies car elles sont facilement observables, et très différentes les unes des autres. Il est donc plus facile pour nous de trier les images mais également pour faciliter le développement de l'IA. Cette banque nous fournit également l'âge et le sexe des patients, ce qui nous a permis d'effectuer une étude statistique par cohorte.

II - Le tri des maladies à la main

A) Les techniques d'identification des maladies




Figure 2 : Radiographie d'une cardiomégalie

Les clichés de la banque initiale étant mal triés, nous avons dû créer notre propre banque d'images bien représentatives de chacune des maladies étudiées.

Il est alors nécessaire de reconnaître ces pathologies et les astuces pour différencier les marqueurs de vieillesse naturels des vraies maladies, grâce aux indications de la radiologue^[A].

La cardiomégalie (*Figure 2*) est une inflammation du cœur. Elle est visible sur une radiographie en étudiant la largeur de la silhouette cardiaque par rapport à la largeur de la cage thoracique : si ce rapport a une valeur supérieure à 0,5 alors le patient est souffrant.

La deuxième maladie facile à reconnaître est l'emphysème (*Figure 3*). Cette maladie correspond à une distension du poumon qui est trop rempli d'air. Le poumon est alors plus noir que la normale sur la radiographie et l'espace entre les côtes est plus grand. Les trames pulmonaires se font plus rares car les alvéoles sont détruites et remplacées par de grosses poches d'air.




Figure 4 : Radiographie d'une pneumopathie franche lobaire aiguë

Nous avons ensuite étudié les pneumonies (*Figure 4*) où les alvéoles remplacent l'air en se remplissant de liquide ou de pus. Ce liquide apparaît en blanc sur les radiographies. Il existe deux types de pneumonie :

- La **pneumonie franche lobaire aiguë** : le liquide est concentré dans une partie du poumon.
- Le **syndrome alvéolo-interstitiel** : la condensation se trouve partout dans le poumon, en taches.




Figure 3 : Comparaison Emphysème / Sain

Nous ne nous sommes par la suite concentrés que sur la forme de pneumonie franche lobaire aiguë, car c'est la forme la plus commune et la plus facile à reconnaître pour l'IA.

Enfin, les masses (*Figure 5*) sont des taches blanches plus ou moins rondes qui peuvent être bénignes ou cancérigènes. Pour plus de précisions sur la nature de cette masse, le scanner s'impose.




Figure 5 : Radiographie d'une masse

Nous avons donc trié ces 4 différentes maladies en vérifiant ensuite avec la radiologue que notre tri est conforme. Nous avons trié environ 5000 images parmi les 100000 pour obtenir une banque de 491 clichés (*Tableau 1*). Cette banque créée est celle sur laquelle l'IA s'entraîne ensuite.

Classes	Cardiomégalie	Emphysème	Masse	Pneumonie	Sain
Nombre d'images triées	202	31	31	47	180

Tableau 1 : Nombre d'images triées

B) Etude statistique sur l'âge et le sexe

Peu d'études statistiques sont réalisées dans les hôpitaux, cependant, le docteur Barcelo^[A] nous a donné quelques pistes d'analyses pour nous permettre de faire nous-même ces graphes et de les interpréter.

Nous avons fait cette étude statistique pour voir si nous pouvions prendre en compte l'âge et le sexe du patient pour perfectionner l'IA. En effet, si une maladie est plus probable à une certaine tranche d'âge qu'à une autre, il est intéressant que l'IA le sache lors de la détermination de l'image.

Pour cela, nous avons créé une interface de tri automatique pour recueillir depuis la banque initiale l'effectif de chacune des maladies sur chaque tranche d'âge (*Tableau 2*) et l'effectif en fonction du sexe des patients.

Age	Cardiomégalie	Emphysème	Masse	Pneumonie
1-10	19	19	17	20
11-20	55	64	95	24
21-30	156	65	265	53
31-40	174	66	264	59
41-50	209	106	436	61
51-60	243	225	575	52
61-70	151	236	375	37
71-80	70	91	96	11
81-90	15	20	16	5
91-100	1	0	0	0
Total	1093	892	2139	322

Tableau 2 : Effectifs collectés de chacune des maladies à partir de l'étude de l'America's Research Hospital

Nous avons alors calculé l'intervalle de confiance à 95% (*Figures 6 et 7*) pour élaborer les graphes :

$$I = \left[p - 1,96 \sqrt{\frac{p(1-p)}{n}} ; p + 1,96 \sqrt{\frac{p(1-p)}{n}} \right] \text{ avec } p = \frac{n_0}{n} .$$

n_0 = Effectif de personnes atteintes dans la maladie dans la tranche d'âge / par sexe

n = Effectif total de personnes atteintes de la maladie




Figure 6 : Répartition des maladies étudiées par tranche d'âge




Figure 7 : Répartition des maladies étudiées selon le sexe

Il nous paraît évident que l'effectif général augmente avec l'âge, avec la fragilité. Néanmoins, l'interprétation du nuage de points et des intervalles de confiance mettent en avant des différences notables vers l'âge de 30 ans (*Figure 6*) entre la pneumonie et les autres maladies, qui pourraient être dues à des facteurs abiotiques non discernés. La radiologie a toutefois dit observer une augmentation du nombre de pathologies chez les jeunes hommes (18-25 ans) grands et fins, dont la croissance rapide favorise le détachement du poumon de la cage thoracique.


Nous avons également effectué une étude statistique du pourcentage d'hommes et de femmes atteints de chacune des maladies (*Figure 7*).

Nous observons généralement que plus d'hommes sont atteints de maladies que les femmes. Cette tendance est ancienne et provient du fait que davantage d'hommes que de femmes fumaient et buvaient. La radiologue nous a affirmé que cette tendance n'est plus d'actualité et que les histogrammes pourraient se rapprocher dans le futur.

Les résultats obtenus, bien qu'étant issues d'un nombre important de données peuvent ne pas représenter la réalité puisque nous ne savons pas comment ont été récoltées les radiographies. En effet, le biais de recrutement des images est différent en fonction des cliniques. Nous avons donc décidé de ne pas prendre en compte l'âge et le sexe dans l'IA par la suite.

III - La création de l'intelligence artificielle

A) Fonctionnement du réseau neuronal convolutif



L'intelligence artificielle avec laquelle nous travaillons est un réseau neuronal convolutif^[5] (*Figure 8*) (Convolutional Neural Network) bien adapté à l'apprentissage automatique dans le domaine de la reconnaissance d'images. Il prend en entrée une image de radiographie au format PNG (matrices de valeurs de pixels pour les plans Rouge-Vert-Bleu) dont il connaît la pathologie et capture avec succès la démarcation des organes et du contour du corps, grâce à l'application de filtres pertinents. La matrice simplifiée est alors dans un réseau de neurones artificiel qui est entraîné avec notre banque d'images et qui prédit la maladie.

Pour expliquer son fonctionnement, nous allons illustrer l'avancement de l'entrée d'une image de taille réduite (5×5 pixels) au travers du réseau. Le réseau débute par une couche de convolution (*Figure 9*), dans laquelle chaque plan RGB est balayé par un noyau de convolution propre (matrice 2×2 dans l'exemple) contenant des « paramètres spécifiques » (ex : 0;1;1;-1) initialement aléatoires. Nous avons représenté trois positionnements de noyaux (jaune, orange et rose) possibles qui illustrent le décalage case par case de la gauche vers la droite et de haut en bas de ceux-ci pour appliquer les paramètres spécifiques aux matrices.




Figure 9 : Balayage de l'image par les noyaux de convolution

Il en résulte une carte de caractéristiques de sortie (*Figure 10*).

-505	201	224	-108
476	416	246	44
58	268	88	103
287	366	-64	423

Figure 10 : Carte de caractéristiques de sortie

Sont ensuite appliquées différentes fonctions telles que *ReLU* ^[6] (qui affecte 0 aux valeurs négatives dans la matrice), *MaxPooling* (qui simplifie la matrice en ne gardant que des valeurs maximales) pour améliorer l'efficacité du traitement, tout en accélérant l'entraînement. Cette matrice finale entre enfin dans un réseau de neurones artificiel où elle modifiera d'autres matrices contenant de nouveaux paramètres spécifiques pour aboutir à une couche de prédiction : probabilité pour chacune des cinq classes (4 maladies plus une classe de personnes saines).

Au final, il effectue une « rétropropagation du gradient » ^[7], algorithme qui fait marche arrière dans les couches pour modifier les paramètres spécifiques afin que la couche de prédiction ait les valeurs attendues (dans l'idéal 1 pour la maladie prévue et 0 pour les autres) lors de l'entraînement.

B) Création du programme informatique

Nous avons créé un programme basé sur ce modèle d'intelligence artificielle pour identifier nos maladies étudiées. Nous avons choisi les filtres qui seraient intéressants pour la détection des maladies et nous avons entraîné l'IA sur notre propre banque d'image. Nous avons créé une interface graphique générée par le module *Tkinter* et codée en langage Python. L'utilisateur choisit la radiographie à identifier depuis son gestionnaire de dossiers, puis le programme récupère cette image et l'applique au modèle (réseau neuronal). Ce dernier donne sa prédiction pour chacune des classes étudiées en pourcentage.

Nous reconnaissons l'enchaînement des étapes décrites précédemment pour créer le réseau neuronal (*Figure 11*). Ces fonctions sont préexistantes, issues de l'outil open source *TensorFlow* mais nous les avons adaptées à nos images. Une fois la prédiction dévoilée, l'utilisateur a la possibilité de récupérer les images après l'application de chaque filtre.

Figure 11 : Script Python du modèle d'intelligence

```
try: #Si le modèle est déjà enregistré, on le charge
    model = tf.keras.models.load_model("model.h5")
except: #Si le modèle n'existe pas, on le crée
    model = tf.keras.Sequential([
        layers.experimental.preprocessing.Rescaling(1./255),
        layers.Conv2D(128, 4, activation='relu'),
        layers.MaxPooling2D(),
        layers.Conv2D(64, 4, activation='relu'),
        layers.MaxPooling2D(),
        layers.Conv2D(32, 4, activation='relu'),
        layers.MaxPooling2D(),
        layers.Conv2D(16, 4, activation='relu'),
        layers.MaxPooling2D(),
        layers.Flatten(),
        layers.Dense(64, activation='relu'),
        layers.Dense(num_classes, activation='softmax')
    ])
```

IV - Résultats et interprétation

A) Présentation des résultats fournis par l'IA

La première chose que l'IA affiche est l'image de la radiographie après application des différentes couches du programme. Ces couches permettent à l'IA d'identifier au préalable les grandes parties de l'image. En effet, il identifie alors les rebords du patient ainsi que la colonne vertébrale, le cœur, l'estomac et les intestins. L'IA reconnaît ce qui est commun à toutes les images et se concentre sur les anomalies présentes sur les clichés.




Figure 12 : Interface graphique et prédiction de l'IA

Après l'analyse de l'image à travers le réseau neuronal, l'IA nous fournit son verdict en pourcentage de chance que ce soit chacune des maladies étudiées.


Ici (*Figure 12*), nous observons que le cœur est anormalement gros, expliquant le verdict.

Il considère que cette image est une cardiomégalie. Cependant, il y a également 10 % de chance que ce soit une pneumonie. Afficher les pourcentages permet donc de nuancer le résultat de la recherche, et nous a permis de mettre en avant les raisons de ces imprécisions.

Sur cet exemple, l'image n'est pas de très bonne qualité, le bas étant très blanc, et trompe en partie l'IA puisque cela ressemble à une pneumonie.

De plus, lorsque l'utilisateur clique sur le bouton *Filtres*, cela enclenche le programme permettant de récupérer le résultat des filtres (*Figure 13*). Il souligne les contours du cœur et accentue la progression des paramètres spécifiques du réseau (palette de couleur du violet au rouge pour des valeurs croissantes).

Figure 13 : Traitement de l'image après les filtres



Après avoir testé la fiabilité de l'IA sur chacune des classes, nous avons obtenu les résultats présentés ci-dessous (*Tableau 3*).

Classes	Cardiomégalie	Emphysème	Masse	Pneumonie	Sain	Moyenne pondérée
Taux de réussite	96,04%	87,10%	77,42%	87,23%	77,78%	86,76%

Tableau 3 : Taux de réussite de l'IA sur chacune des classes et sur l'ensemble des images

Le taux de réussite global semble convenable pour nos moyens d'étude limités mais des écarts d'erreur sont notables, en particulier pour les individus sains. Même si considérer une personne saine comme étant malade est moins grave que l'inverse, ce résultat s'écarte de notre objectif principal.

B) Quelques erreurs de l'IA et les améliorations possibles

Nous avons observé que ses erreurs sont souvent les mêmes. Par exemple, le logiciel se trompe assez souvent entre une personne saine et une personne ayant des masses. Nous avons donc analysé les images caractéristiques de ses erreurs pour mettre en avant les améliorations à apporter à l'IA.




Figure 14 : Patient sain confondu avec une masse

Par exemple, l'IA considère l'image de la *Figure 14* comme représentant un poumon avec une masse alors que cette personne est en fait saine. Cette erreur est sûrement due aux alvéoles qui sont, par endroit, plus marquées et qu'elle assimile donc à une masse.

Le problème se pose chez les personnes âgées chez qui les alvéoles sont généralement plus visibles (marquage rouge).

De plus, l'ombre de la crosse aortique est plus apparent chez certaines personnes que chez d'autres, ce qui peut induire en erreur l'IA (marquage bleu).

Nous avons entraîné le réseau sur une banque d'image dans laquelle il n'y a que très peu de personnes âgées. En rajoutant plus d'images, l'IA apprendrait que des alvéoles marquées ne sont pas toujours synonymes de masse.

Sur ce nouvel exemple (*Figure 15*), la cardiomégalie est tellement étendue dans le poumon que l'IA la confond avec une pneumonie.

Il faut donc ajouter au facteur morphologique un facteur physiologique. Ainsi, l'IA comprendrait qu'il ne s'agit pas d'une pneumonie mais d'une inflammation du cœur.




Figure 15 : Cardiomégalie confondue avec une pneumonie

Nous voyons qu'étonnamment les erreurs fournies par l'IA découlent de la détermination d'images saines. L'IA identifie certaines pathologies alors qu'il n'y a rien à voir. Cela est sûrement dû au fait que nous n'avons pas trié assez d'images montrant des personnes saines. Or, ce qui est nécessaire dans le service médical est que l'IA ne fasse pas d'erreur lorsqu'elle affirme que la personne est en bonne santé. Il faudrait donc augmenter le nombre de personnes saines sur lesquelles elle s'entraîne.

Conclusion

L'intelligence artificielle est capable de reconnaître certaines maladies à l'aide de simples clichés radiographiques. Ainsi, cette intelligence permet de prévenir les maladies thoraciques, car elle permet un premier tri des images. Celui-ci assure le désengorgement des services de radiologie des hôpitaux, en priorisant les patients les plus malades. L'intelligence reconnaît cinq classes distinctes avec un faible taux d'erreur, que nous pourrions améliorer en rajoutant des maladies pour avoir une analyse plus fine. De plus, il est essentiel que le tri des personnes saines soit véridique pour éviter de renvoyer des personnes malades. L'intelligence artificielle appliquée aux services médicaux de radiologies doit être fondée sur une base de données très importante et développée par un réseau neuronal complexe qui demande une ressource informatique que nous ne possédons pas. Elle prend de plus en plus d'importance dans le domaine médical, en particulier dans la classification d'images par réseau neuronal, au travers d'un apprentissage automatique.

Sitographie

Les dates de consultation sont indiquées entre parenthèses.

[1] HAZEBROUCQ Vincent, Maître de conférences à l'Université Paris Descartes « Le secret médical, ce que le radiologue hospitalier doit en savoir et en faire » (15 mars 2022)

https://www.srh-info.org/userfile/radiovigilance/1_2014.pdf

[2] Clinical Center – America's Research Hospital (2 décembre 2021)

<https://nihcc.app.box.com/v/ChestXray-NIHCC/file/219760887468>

[3] Fonctionnement de la radiographie (10 octobre 2021)

<https://www.info-radiologie.ch/radiographie.php>

[4] Université de Californie, San Diego (13 janvier 2022)

[https://www.cell.com/cell/fulltext/S0092-8674\(18\)30154-5#back-bib6](https://www.cell.com/cell/fulltext/S0092-8674(18)30154-5#back-bib6)

[5] SAHA Sumit, Développeur « A Comprehensive Guide to Convolutional Neural Networks - the ELI5 way » (12 février 2022)

<https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53>

[6] KELDENICH Tom, Data Engineer « Fonction d'activation, comment ça marche ? - Une explication simple » (20 mars 2022)

<https://inside-machinelearning.com/fonction-dactivation-comment-ca-marche-une-explication-simple/>

[7] VANCAPPEL Kévin, Expert Digital « Deep Learning : le Réseau neuronal convolutif (CNN) (20 mars 2022)

<https://fr.blog.businessdecision.com/tutoriel-deep-learning-le-reseau-neuronal-convolutif-cnn/>

Contact

[A] Docteur Céline Barcelo, radiologue au Centre d'Imagerie médicale du Parc à Toulouse - Communication personnelle le 15 novembre 2021.

Remerciements au Docteur Barcelo qui nous a permis d'identifier les maladies choisies et qui a bien voulu vérifier les images sélectionnées.